



# 模式识别

课程团队：谢凤英 崔林艳 张浩鹏

邹征夏 李洪珏 李家军

单位：宇航学院

# 第二章 线性分类器

CONTENTS PAGE

2.1 基本概念和数学基础

2.2 线性分类器基础

2.3 垂直平分分类器

2.4 Fisher投影准则

2.5 感知准则

2.6 最小错分样本数准则

2.7 最小平方误差准则

## 2.1 基本概念和数学基础

---

2.1.1 决策面和判别函数

2.1.2 分类问题描述

2.1.3 模式识别的数学基础

## 2.1 基本概念和数学基础




### 2.1.1 决策面和判别函数

- 分类是模式识别的本质
- 基于样本集设计分类器的过程就是寻找分类决策边界的过程
- 在特征空间中，将不同种类样本区分开的决策边界，称之为“决策面”或“分类面”
- 用数学形式描述决策面的函数就是判别函数

## 2.1 基本概念和数学基础

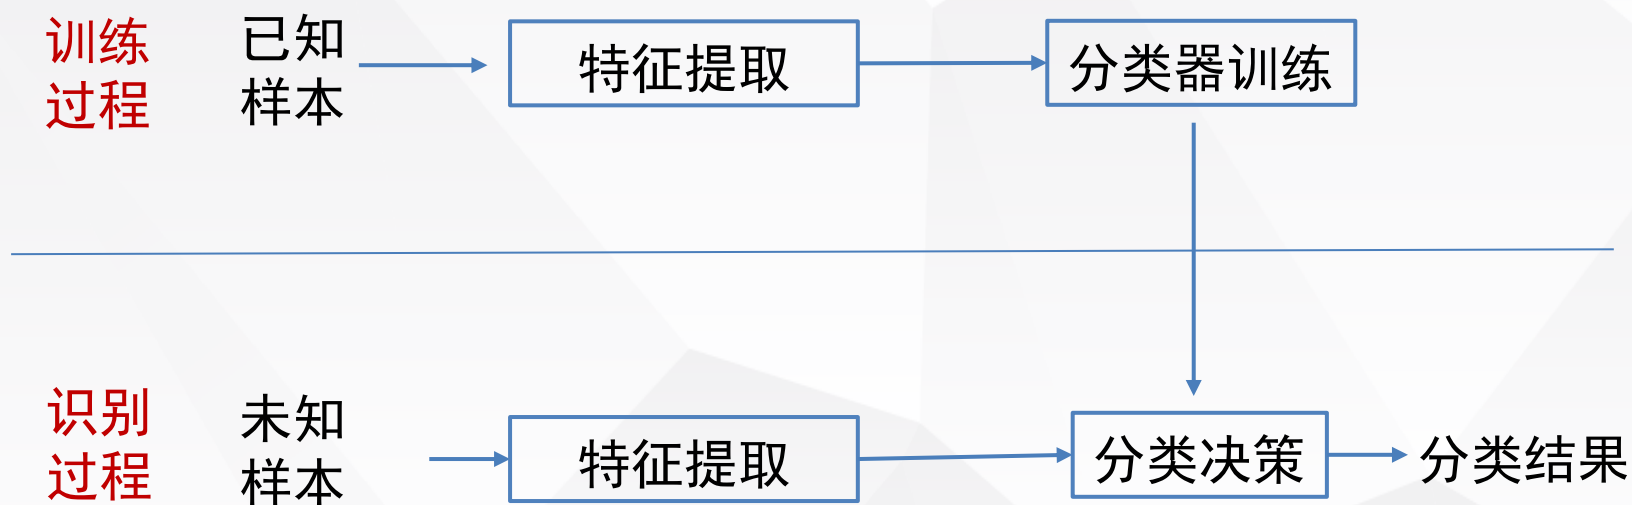
例：在二维特征空间中，二分类任务可以有多种决策边界（决策面、分类面）

遥感图像舰船目标二分类（军船 VS 民船）



## 2.1 基本概念和数学基础

### 训练过程与识别过程



# 2.1 基本概念和数学基础

## 2.1.2 分类问题描述

- $C$ ——类别数
- $D$ ——特征维度
- $N$ ——样本数

例：

- 两类二维问题：在二维特征空间中的二分类， $C=2$ ， $D=2$
- 三类多维问题：在多维特征空间中的三分类， $C=3$ ， $D>2$

## 2.1 基本概念和数学基础

### 2.1.3 模式识别的数学基础

- 线性代数

- 矩阵、向量、转置、向量运算、矩阵运算……

- 概率统计

- 概率、条件概率、分布、概率密度函数、期望方差……

- 最优化

- 最小二乘、梯度下降……



## 2.2 线性分类器基础

---

2.2.1 线性分类器概念

2.2.2 线性判别函数

2.2.3 增广变换


2.2.4 线性分类器设计

2.2.5 归纳小结

## 2.2 线性分类器基础

### 2.2.1 线性分类器概念

- **线性分类器**：对于两类的分类问题，采用线性判别函数划分特征空间（即采用直线或平面等将两类样本在特征空间中的区域划分开），这样的分类器是线性分类器。



## 2.2 线性分类器基础

### 2.2.2 线性判别函数

➤ 两类二维问题（ $C=2$ ,  $D=2$ ）

➤ 直线方程（决策面）

➤ 代数形式

$$w_1x_1 + w_2x_2 + w_0 = 0$$

➤ 向量形式

$$\mathbf{w}^T \mathbf{x} + w_0 = 0$$

➤ 定义线性判别函数

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

## 2.2 线性分类器基础

### 2.2.2 线性判别函数

➤ 两类多维问题 ( $C=2$ ,  $D>2$ )

➤ 定义线性判别函数

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

$\mathbf{w}$ : 权重向量       $w_0$ : 偏置系数

➤ 决策面H



$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = 0$$

## 2.2 线性分类器基础

### 2.2.2 线性判别函数

➤ 线性分类器决策面 $H$ 在不同维度特征空间的表现形式

特征维度	一维 ( $D = 1$ )	二维 ( $D = 2$ )	三维 ( $D = 3$ )	多维 ( $D > 3$ )
决策面情况	点	直线	平面	超平面



## 2.2 线性分类器基础


### 2.2.2 线性判别函数

➤ 线性判别函数的几何性质

➤ 法向量方向  $\mathbf{w}$

➤ 原点距离  $|w_0| / \|\mathbf{w}\|$

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$



## 2.2 线性分类器基础

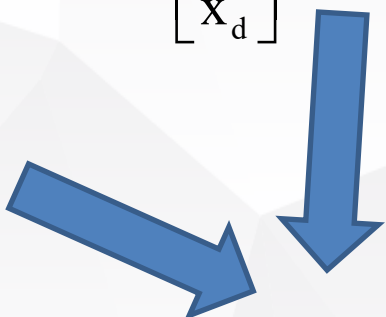
### 2.2.3 增广变换

➤ 线性判别函数  $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$  的增广变换

➤ 对原特征 $\mathbf{x}$ 定义增广变换

➤ 对应权向量  $\mathbf{a} = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} w_0 \\ \mathbf{w} \end{bmatrix}$

$$\mathbf{y} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} 1 \\ \mathbf{x} \end{bmatrix}$$


$$g(\mathbf{x}) = \mathbf{a}^T \mathbf{y}$$

## 2.2 线性分类器基础

### 2.2.3 增广变换

➤ 线性判别函数  $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$  的增广变换为

$$g(\mathbf{x}) = \mathbf{a}^T \mathbf{y}$$

$\mathbf{a}$ : 增广后权重向量

$y$ : 增广后偏置系数

➤ 增广变换的特点

➤ 特征维数增加了一维:  $D_G = D + 1$

➤ 样本之间的欧氏距离保持不变

➤ 增广变换后的决策面  $\mathbf{a}^T \mathbf{y} = 0$  是过原点的超平面  $H_G$



## 2.2 线性分类器基础

### 2.2.3 增广变换

#### ➤ 决策规则

➤ 已知判别函数  $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$  或  $g(\mathbf{x}) = \mathbf{a}^T \mathbf{y}$

➤ 决策规则为：

对于未知样本 $\mathbf{x}$ ,

若 $g(\mathbf{x}) > 0$ , 则 $\mathbf{x}$ 决策为 $\omega_1$ 类（正类, 特征空间正侧）

若 $g(\mathbf{x}) < 0$ , 则 $\mathbf{x}$ 决策为 $\omega_2$ 类（负类, 特征空间负侧）

## 2.2 线性分类器基础

### 2.2.4 线性分类器设计

- 线性分类器设计常规步骤
  - 给定类别已知的样本——训练样本集
  - 选择一个**准则函数 $J$** ，其值反映分类器性能（分类结果优劣）
  - 采用求最优解的数学方法求准则函数 $J$ 的极值解，从而求得权重向量 $\mathbf{w}$ 和偏置 $w_0$ ，或增广权重向量 $\mathbf{a}$

## 2.2 线性分类器基础

### 2.2.4 归纳小结

- 线性分类器特点：简单高效，适合解决线性可分问题
- 采用增广表达可使问题表达形式更加简洁
- 线性分类器的核心在于求解权重向量和偏置

## 2.3 垂直平分分类器

---

2.3.1 问题与思路

2.3.2 垂直平分分类器求解


2.3.3 最小距离等价决策

2.3.4 归纳小结

## 2.3 垂直平分分类器

### 2.3.1 问题与思路

- 二分类问题 ( $C=2$ )，已知训练样本集 $X$ 有 $N$ 个样本，其中
  - $\omega_1$ 类样本有 $N_1$ 个，样本集用 $X_1$ 表示；
  - $\omega_2$ 类样本有 $N_2$ 个，样本集用 $X_2$ 表示
- 垂直平分分类器设计思路：
  - 基于两类样本均值点作**垂直平分线**



## 2.3 垂直平分分类器

### 2.3.2 垂直平分分类器求解

- 判别函数与决策面方程

- 垂直平分线性判别函数

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

- 决策面方程（垂直平分直线方程）

$$g(\mathbf{x}) = 0 \quad \text{即} \quad \mathbf{w}^T \mathbf{x} + w_0 = 0$$

## 2.3 垂直平分分类器

### 2.3.2 垂直平分分类器求解

- 求解权向量与阈值权
  - 先求均值向量 $\mathbf{m}_1$ 和 $\mathbf{m}_2$
  - 利用垂直几何关系，设权向量

$$\mathbf{w} = \mathbf{m}_1 - \mathbf{m}_2$$

- 则直线方程为

$$(\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{x} + w_0 = 0$$

正侧在 $\mathbf{m}_1$ 侧

## 2.3 垂直平分分类器

### 2.3.2 垂直平分分类器求解

➤ 求解权向量与阈值权

➤ 再利用平分几何关系，中点 $\mathbf{x}_0$ 在直线上

$$\mathbf{x}_0 = (\mathbf{m}_1 + \mathbf{m}_2) / 2$$

➤ 代入方程求得偏置量

$$w_0 = -(\mathbf{m}_1 - \mathbf{m}_2)^T (\mathbf{m}_1 + \mathbf{m}_2) / 2$$



## 2.3 垂直平分分类器

### 2.3.2 垂直平分分类器求解

#### ➤ 最终结果

➤ 线性判别函数 
$$g(\mathbf{x}) = (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{x} - (\mathbf{m}_1 - \mathbf{m}_2)^T (\mathbf{m}_1 + \mathbf{m}_2) / 2$$
$$= (\mathbf{m}_1 - \mathbf{m}_2)^T (\mathbf{x} - (\mathbf{m}_1 + \mathbf{m}_2) / 2)$$

#### ➤ 决策面方程

$$(\mathbf{m}_1 - \mathbf{m}_2)^T (\mathbf{x} - (\mathbf{m}_1 + \mathbf{m}_2) / 2) = 0$$

## 2.3 垂直平分分类器

### 2.3.2 垂直平分分类器求解

#### ➤ 决策规则

#### ➤ 已知垂直平分判别函数

$$g(\mathbf{x}) = (\mathbf{m}_1 - \mathbf{m}_2)^T (\mathbf{x} - (\mathbf{m}_1 + \mathbf{m}_2) / 2)$$

#### ➤ 垂直平分决策规则为

对于未知样本 $\mathbf{x}$ ，若 $g(\mathbf{x}) > 0$ ，则 $\mathbf{x}$ 决策为 $\omega_1$ 类

若 $g(\mathbf{x}) < 0$ ，则 $\mathbf{x}$ 决策为 $\omega_2$ 类

## 2.3 垂直平分分类器

### 2.3.2 垂直平分分类器求解

- 推广到两类多维问题（ $C=2$ ， $D>2$ ）判别函数与决策面方程形式不变

- 垂直平分线性判别函数

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

- 垂直平分决策面方程

$$g(\mathbf{x})=0 \quad \text{即} \quad \mathbf{w}^T \mathbf{x} + w_0 = 0$$

## 2.3 垂直平分分类器

### 2.3.3 最小距离等价决策

- 定义判别函数为欧氏距离（非线性）

$$G_1(\mathbf{x}) = d_1(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}_1\|$$


$$G_2(\mathbf{x}) = d_2(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}_2\|$$

- 垂直平分分类器等价的最小距离决策规则为

对于未知样本 $\mathbf{x}$ ，若 $d_1(\mathbf{x}) < d_2(\mathbf{x})$ ，则 $\mathbf{x}$ 决策为 $\omega_1$ 类

若 $d_1(\mathbf{x}) > d_2(\mathbf{x})$ ，则 $\mathbf{x}$ 决策为 $\omega_2$ 类

- 垂直平分分类器又叫**最小距离分类器**



## 2.3 垂直平分分类器

### 2.3.4 归纳小结

- 垂直平分分类器的主要特点
  - 解决二分类问题的线性分类器，简单直观
  - 未采用准则函数求极值解（非最佳决策）
  - 垂直平分分类器可等价于最小距离分类器

## 2.4 Fisher投影准则

---

2.4.1 问题与思路

2.4.2 Fisher准则函数

2.4.3 准则函数化简


2.4.4 求极值解

2.4.5 归纳小结

## 2.4 Fisher投影准则

### 2.4.1 问题与思路

- 高维问题：特征个数多、特征空间维数高、计算量大
  - 用经典理论设计分类器困难
- 设计思路
  - 通过投影对高维分类问题降维
  - Fisher将高维特征空间的样本投影到一维直线上



## 2.4 Fisher投影准则

### 2.4.1 问题与思路

➤ 问题：


- 已知 $C=2$ ， $D$ 维分类问题的样本集
- 设投影向量为 $\mathbf{w}$
- 则一维投影方程为  $y = \mathbf{w}^T \mathbf{x}$
- 求最佳投影向量 $\mathbf{w}$



## 2.4 Fisher投影准则

### 2.4.2 Fisher准则函数

- Fisher投影准则的物理含义
  - 投影后异类样本尽量远离
  - 投影后同类样本尽量靠近



## 2.4 Fisher投影准则

### 2.4.2 Fisher准则函数

➤ 在原特征空间 $X$ 中

➤ 类均值向量

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\mathbf{x}_j \in X_i} \mathbf{x}_j, i = 1, 2$$

➤ 类内离散度矩阵

$$\mathbf{S}_i = \sum_{\mathbf{x}_j \in X_i} (\mathbf{x}_j - \mathbf{m}_i)(\mathbf{x}_j - \mathbf{m}_i)^T, i = 1, 2$$

➤ 总类内离散度矩阵

$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$$

➤ 类间离散度矩阵

$$\mathbf{S}_b = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T$$

## 2.4 Fisher投影准则

### 2.4.2 Fisher准则函数

➤ 在投影后的一维特征空间 $Y$ 中

➤ 类均值 
$$\tilde{m}_i = \frac{1}{N_i} \sum_{y_j \in Y_i} y_j = \frac{1}{N_i} \sum_{x_j \in X_i} \mathbf{w}^T \mathbf{x}_j = \mathbf{w}^T \mathbf{m}_i, i = 1, 2$$

➤ 类内离散度 
$$\tilde{S}_i^2 = \sum_{y_j \in Y_i} (y_j - \tilde{m}_i)^2, i = 1, 2$$

➤ 总类内离散度 
$$\tilde{S}_w^2 = \tilde{S}_1^2 + \tilde{S}_2^2$$

➤ 类间离散度 
$$\tilde{S}_b^2 = (\tilde{m}_1 - \tilde{m}_2)^2$$

## 2.4 Fisher投影准则

### 2.4.2 Fisher准则函数

➤ Fisher准则函数定义

$$J_F(\mathbf{w}) = \frac{\tilde{S}_b^2}{\tilde{S}_w^2} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

➤ Fisher准则函数值越大，投影结果越符合预期

➤ 投影后异类样本尽量远离

➤ 投影后同类样本尽量靠近

## 2.4 Fisher投影准则

### 2.4.3 准则函数化简

$$J_F(\mathbf{w}) = \frac{\tilde{S}_b^2}{\tilde{S}_w^2} = \frac{(\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

➤ 分子化简

$$\begin{aligned}\tilde{S}_b^2 &= (\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2)^2 \\ &= (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2)^2 \\ &= \mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w} \\ &= \mathbf{w}^T \mathbf{S}_b \mathbf{w}\end{aligned}$$

## 2.4 Fisher投影准则

### 2.4.3 准则函数化简

$$J_F(\mathbf{w}) = \frac{\tilde{S}_b^2}{\tilde{S}_w^2} = \frac{(\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

➤ 分母化简

$$\begin{aligned}\tilde{S}_w^2 &= \tilde{S}_1^2 + \tilde{S}_2^2 \\&= \sum_{\mathbf{x}_j \in X_1} (\mathbf{w}^T \mathbf{x}_j - \mathbf{w}^T \mathbf{m}_1)^2 + \sum_{\mathbf{x}_j \in X_2} (\mathbf{w}^T \mathbf{x}_j - \mathbf{w}^T \mathbf{m}_2)^2 \\&= \sum_{\mathbf{x}_j \in X_1} \mathbf{w}^T (\mathbf{x}_j - \mathbf{m}_1)(\mathbf{x}_j - \mathbf{m}_1)^T \mathbf{w} + \sum_{\mathbf{x}_j \in X_2} \mathbf{w}^T (\mathbf{x}_j - \mathbf{m}_2)(\mathbf{x}_j - \mathbf{m}_2)^T \mathbf{w} \\&= \mathbf{w}^T \mathbf{S}_1 \mathbf{w} + \mathbf{w}^T \mathbf{S}_2 \mathbf{w} \\&= \mathbf{w}^T \mathbf{S}_w \mathbf{w}\end{aligned}$$

## 2.4 Fisher投影准则

### 2.4.3 准则函数化简

$$J_F(\mathbf{w}) = \frac{\tilde{S}_b^2}{\tilde{S}_w^2} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

➤ 化简结果



$$J_F(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

- 这一表达式被称为广义Rayleigh商
- 问题的求解可等价为一个“极大化广义Rayleigh商”的最优化问题

## 2.4 Fisher投影准则

### 2.4.4 求极值解

- 令分母为非零常数，最大化分子部分，转化为等式约束条件下求极值问题

$$\begin{aligned} \max \quad & \mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = c \neq 0 \end{aligned}$$

- 引入Lagrange乘子

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{S}_b \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{S}_w \mathbf{w} - c)$$



## 2.4 Fisher投影准则

### 2.4.4 求极值解

➤ 采用Lagrange乘子法求Fisher准则函数的极值

➤ 求偏导数

➤ 令偏导数为零  $L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{S}_b \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{S}_w \mathbf{w} - c)$

$$\frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = \mathbf{S}_b \mathbf{w} - \lambda \mathbf{S}_w \mathbf{w}$$

$$\mathbf{S}_b \mathbf{w}^* - \lambda \mathbf{S}_w \mathbf{w}^* = 0$$

$$\mathbf{S}_w^{-1} \mathbf{S}_b \mathbf{w}^* = \lambda \mathbf{w}^*$$

## 2.4 Fisher投影准则

### 2.4.4 求极值解

➤ 采用Lagrange乘子法求Fisher准则函数的极值

➤ 重构 $S_b$

$$S_b \mathbf{w}^* = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w}^* = (\mathbf{m}_1 - \mathbf{m}_2)R$$

标量常数  $R = (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w}^*$

$$\mathbf{w}^* = \frac{R}{\lambda} S_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

➤ Fisher准则函数的极值解（极大值）

$$\mathbf{w}^* = S_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

## 2.4 Fisher投影准则

### 2.4.5 归纳小结

- Fisher投影的特点
  - 解决两类问题的线性投影，分类器设计较容易
  - 原则上对样本集无特殊要求 ( $S_w$  矩阵可逆)
  - 采用Fisher投影准则函数求极值解 (最佳决策)

## 2.5 感知准则

---

2.5.1 线性可分问题

2.5.2 解向量和解区

2.5.3 感知准则函数

2.5.4 求极值解



2.5.5 归纳小结

## 2.5 感知准则

### 2.5.1 线性可分问题

#### ➤ 样本集的线性可分性

- 若训练样本集可以被某个线性分类器完全正确分类，则该样本集是**线性可分**的。
- 否则样本集就是线性不可分的



## 2.5 感知准则

### 2.5.2 解向量和解区

#### ➤ 解向量

能将线性可分样本集中的每个样本都正确分类的权向量。

#### ➤ 解区

解向量往往不是一个，而是由无穷多个解向量组成的区域，称为解区。

## 2.5 感知准则

### 2.5.3 感知准则函数

- 线性可分性样本集的规范化

对  $\omega_2$  类（负类）样本的增广向量全部乘以-1

- 规范化之后的分类结果

$\mathbf{a}^T \mathbf{y} > 0$ ，正确分类

$\mathbf{a}^T \mathbf{y} < 0$ ，错误分类

## 2.5 感知准则

### 2.5.3 感知准则函数

➤ Rosenblatt定义感知准则函数（感知机）

➤ 对于规范化的增广样本集， $\mathbf{a}^T \mathbf{y} < 0$  表示错误分类

➤ 定义感知准则函数作为优化目标函数

$$J_p(\mathbf{a}) = \sum_{\mathbf{a}^T \mathbf{y}_k \leq 0} (-\mathbf{a}^T \mathbf{y}_k)$$

➤ 求解向量（或解区）

➤ 梯度下降法求解



## 2.5 感知准则

### 2.5.4 求极值解

➤ 用梯度下降法求解感知准则函数极值（极小值）

➤ 先求梯度方向

$$\nabla J_p(\mathbf{a}) = \frac{\partial J_p(\mathbf{a})}{\partial \mathbf{a}} = \sum_{\mathbf{a}^T \mathbf{y}_k \leq 0} (-\mathbf{y}_k)$$

➤ 得到迭代公式

$$\begin{aligned}\mathbf{a}(t+1) &= \mathbf{a}(t) - \rho_t \nabla J_p(\mathbf{a}) \\ &= \mathbf{a}(t) + \rho_t \sum_{\mathbf{a}^T \mathbf{y}_k \leq 0} \mathbf{y}_k\end{aligned}$$

## 2.5 感知准则

### 2.5.5 归纳小结

- 感知准则（分类器）的特点
  - 解决两类分类的线性分类器构造问题
  - 样本集必须是线性可分的
  - 采用感知准则函数求极值解（最优决策）
- 感知机的后续研究
  - 人工神经网络
  - 支持向量机SVM

## 2.6 最小错分样本数准则

---

2.6.1 问题与思路

2.6.2 最小错分准则

2.6.3 归纳小结

## 2.6 最小错分样本数准则

### 2.6.1 问题与思路

#### ➤ 问题：

- 感知准则只适用线性可分样本集——无错分
- 实际情况未必线性可分——有错分
- 另外线性可分的判断也很困难
- 既然存在错分样本——求错分样本数最少

## 2.6 最小错分样本数准则

### 2.6.1 问题与思路

➤ 数学描述：

➤ 规范化的增广样本集， $\mathbf{a}^T \mathbf{y} < 0$  表示错误分类

➤ 设样本数为 $N$ ， $N$ 个不等式联立

$$\mathbf{a}^T \mathbf{y}_i > 0, \quad i = 1, \dots, N$$

➤ 求满足不等式最多的解（权向量）

## 2.6 最小错分样本数准则

### 2.6.1 问题与思路

➤ 数学描述：

➤ 写成矩阵形式

$$\mathbf{Y}\mathbf{a} > 0$$

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^T \\ \mathbf{y}_2^T \\ \vdots \\ \mathbf{y}_N^T \end{bmatrix} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1d} \\ y_{21} & y_{22} & \cdots & y_{2d} \\ \cdots & \cdots & \cdots & \cdots \\ y_{N1} & y_{N2} & \cdots & y_{Nd} \end{bmatrix}$$

引入余量 $\mathbf{b} > 0$

$$\mathbf{Y}\mathbf{a} \geq \mathbf{b} > 0$$

## 2.6 最小错分样本数准则

### 2.6.2 最小错分准则

➤ 准则函数一

$$J_{q2}(\mathbf{a}) = \sum_{i=1}^N \frac{1 + \text{sgn}(\mathbf{y}_i^T \mathbf{a})}{2} \quad \text{sgn}(\mathbf{y}_i^T \mathbf{a}) = \begin{cases} +1, & \text{对于 } \mathbf{y}_i^T \mathbf{a} \geq 0 \\ -1, & \text{对于 } \mathbf{y}_i^T \mathbf{a} \leq 0 \end{cases}$$

➤ 准则函数二

$$J_{q1}(\mathbf{a}) = \|(\mathbf{Y}\mathbf{a} - \mathbf{b}) - |\mathbf{Y}\mathbf{a} - \mathbf{b}|\|^2$$

➤ 求极值解：搜索算法、梯度下降法

## 2.6 最小错分样本数准则

### 2.6.3 归纳小结

- 最小错分样本数准则（分类器）的特点
  - 解决两类问题的线性分类器
  - 样本集不限，可以是线性不可分的
  - 求满足不等式个数最多的权向量（最优）



## 2.7 最小平方误差准则

---

2.7.1 问题与思路

2.7.2 最小平方误差准则

2.7.3 余量的选择

2.7.4 归纳小结

## 2.7 最小平方误差准则

### 2.7.1 问题与思路

#### ➤ 问题：

- 对于线性不可分问题
- 最小错分样本数准则——求错分样本数最少
- 最小平方误差准则——实际应用中往往是求误差平方和最小

## 2.7 最小平方误差准则

### 2.7.1 问题与思路

➤ 数学描述：

➤ 规范化的增广样本集， $\mathbf{a}^T \mathbf{y} < 0$  表示错误分类

➤ 引入余量 $\mathbf{b}_i$ ，将不等式组改造为等式组

$$\mathbf{a}^T \mathbf{y}_i = \mathbf{b}_i > 0, \quad i = 1, \dots, N$$

➤ 求满足等式组的最小平方误差解（权向量）

## 2.7 最小平方误差准则

### 2.7.1 问题与思路

➤ 数学描述：

➤ 写成矩阵形式  $\mathbf{Y}\mathbf{a} = \mathbf{b}$

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^T \\ \mathbf{y}_2^T \\ \vdots \\ \mathbf{y}_N^T \end{bmatrix} = \begin{bmatrix} y_{11} & \cdots & y_{1d} \\ \vdots & \ddots & \vdots \\ y_{N1} & \cdots & y_{Nd} \end{bmatrix}$$

$$\mathbf{b} = [b_1 \ b_2 \ \cdots \ b_N]^T$$

## 2.7 最小平方误差准则

### 2.7.2 最小平方误差准则

- 定义决策误差

$$\mathbf{e} = \mathbf{Y}\mathbf{a} - \mathbf{b}$$

- 定义最小平方误差准则函数

$$J_s(\mathbf{a}) = \|\mathbf{Y}\mathbf{a} - \mathbf{b}\|^2 = \sum_{i=1}^N (\mathbf{a}^T \mathbf{y}_i - b_i)^2$$

## 2.7 最小平方误差准则

### 2.7.2 最小平方误差准则

➤ 直接求极值解

$$\nabla J_s(\mathbf{a}) = 2\mathbf{Y}^T(\mathbf{Y}\mathbf{a} - \mathbf{b}) = 0$$

$$\mathbf{a}^* = (\mathbf{Y}^T\mathbf{Y})^{-1}\mathbf{Y}^T\mathbf{b} = \mathbf{Y}^+\mathbf{b}$$

$$\mathbf{Y}^+ = (\mathbf{Y}^T\mathbf{Y})^{-1}\mathbf{Y}^T$$

## 2.7 最小平方误差准则

### 2.7.3 余量的选择

➤ 选择不同余量的结果

例1

$$\mathbf{b} = \begin{bmatrix} N / N_1 \\ \vdots \\ N / N_1 \\ N / N_2 \\ \vdots \\ N / N_2 \end{bmatrix} \quad \left. \begin{array}{l} \text{ } \\ \text{ } \\ \text{ } \end{array} \right\} \begin{array}{l} N_1 \text{ 个} \\ \\ N_2 \text{ 个} \end{array}$$

➤ 等价于Fisher解

## 2.7 最小平方误差准则

### 2.7.3 余量的选择

- 选择不同余量的结果

例2

$$\mathbf{b}_i = 1, \quad i = 1, \dots, N$$

- 当N趋于无穷时，逼近Bayes解



## 2.7 最小平方误差准则

### 2.7.4 归纳小结

- 最小平方误差准则（分类器）的特点
  - 解决两类问题的线性分类器
  - 样本集不限，可以是线性不可分的
  - 求最小平方误差的权向量，存在闭式解

## 2.8 多分类算法设计

---

2.8.1 问题与思路

2.8.2 一对一法

2.8.3 一对多法


2.8.4 有向无环图法

2.8.5 归纳小结

## 2.8 多分类算法设计

### 2.8.1 问题与思路

- 问题：现实世界中要处理的分类问题往往是多类别的
- 思路：
  - 基于二类分类算法构造多类分类器



## 2.8 多分类算法设计

### 2.8.2 一对一法 (One-Versus-One, OVO)

- 原理：类别两两组合，一对一调用模型进行训练和分类

第一个分类器只回答“是第1类还是第2类”

第二个分类器只回答“是第1类还是第3类”

.....

$c$ 个类别，则需构造 $c(c-1)/2$ 个分类器，投票多的为胜者

- 缺点：类别数多时，分类器数量太多，假如有1000个类别，则需约要500,000个分类器

## 2.8 多分类算法设计

### 2.8.3 一对多法 (One-Versus-Rest, OVR)

➤ 原理：某个类别作为正类，剩余类作为反类

$c$ 个类别的样本可以构造出 $c$ 个二分类器

分类时将未知样本分类为具有最大分类函数值的那类

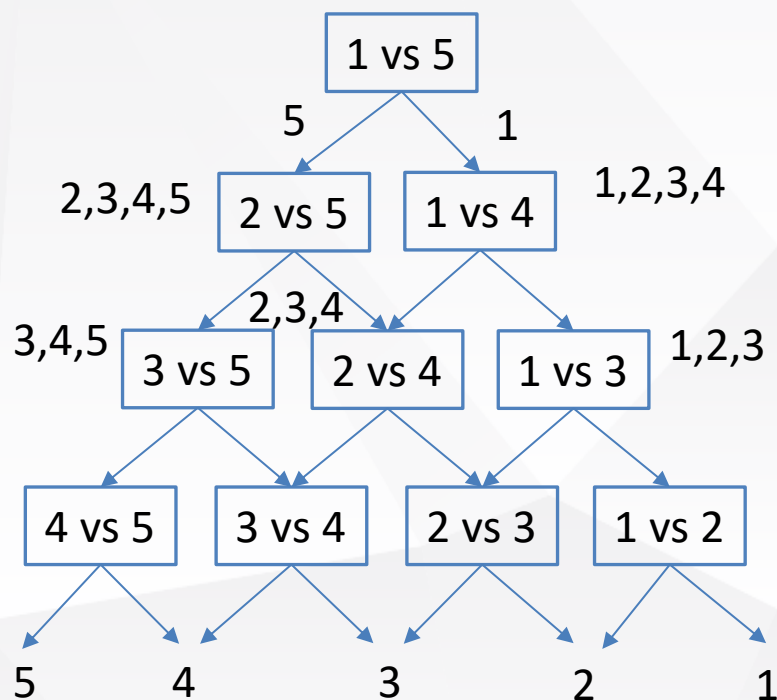
➤ 优点：所需分类器个数较少，分类速度相对较快

➤ 缺点：若“其余”一类数据大，会导致“类别不平衡”问题

## 2.8 多分类算法设计

### 2.8.4 有向无环图法 (Directed Acyclic Graph, DAG)

- 原理：属一对一策略中的一种方法，采用一对一方法训练，但按有向无环图组织分类器进行分类



有向无环图法示意图

- 优点：分类速度快
- 缺点：如最一开始就分类错误，则后面的分类器无法纠正错误

## 2.8 多分类算法设计

### 2.8.4 有向无环图法 (Directed Acyclic Graph, DAG)

#### 一对一法&有向无环图法对比

	一对一法 (OVO)	一对多法 (OVR)	有向无环图法 (DAG)
训练分类器	$c(c-1)/2$ 个	$c$ 个	$c(c-1)/2$ 个
调用分类器	$c(c-1)/2$ 个	$c$ 个	$c-1$ 个
优点	设计思想简单	训练和识别速度快	识别阶段速度快
缺点	不适合类别较多场景	可能出现类别不平衡	如最一开始就分类错误, 则后面的分类器无法纠正错误

- 假如有1000个类别:
- OVO法训练约50万个分类器, 分类时调用这50万个分类器, 按投票多者统计
- DAG法训练50万个分类器, 分类时调用999个分类器

## 2.8 多分类算法设计

### 2.7.5 归纳小结

- 组合多个二类分类器是解决多分类问题的一个常用思路
- 一对一、一对多、有向无环图三种方式都可以用于解决多分类问题
- 三种方法各有优缺点，实际问题中可根据各自的特点进行方法的选择



## 作业

已知

甲类:  $[0\ 3]^T$ 、 $[2\ 4]^T$ 、 $[1\ 3]^T$ 、 $[2\ 3]^T$ 、 $[0\ 2]^T$

乙类:  $[4\ 1]^T$ 、 $[3\ 2]^T$ 、 $[2\ 1]^T$ 、 $[3\ 0]^T$ 、 $[3\ 1]^T$

待分类样本为  $x = [5\ 0]^T$

试用垂直平分判别函数对 $x$ 进行决策, 判断其属于哪一类。

## 作业

对于二维线性判别函数  $g(x) = 3x_1 + 2x_2 - 5$

1) 将判别函数写成向量形式  $g(x) = w^T x + w_0$

2) 映射成广义齐次线性函数  $f(y) = w_1^T y$ , 其中

$$y = (y_1, y_2, y_3)^T = (x_1, x_2, 1)^T$$

3) 证明上述  $X$  空间只是  $Y$  空间的一个子空间, 且

$f(y) = 0$  对  $X$  空间的划分结果与  $g(x) = 0$  相同。

## 作业

已知两类  $\omega_1: (0,0)^T, (1,2)^T, \omega_2: (1,-1)^T, (3,0)^T$ ，请用 Fisher 准则构造分类器，确定最佳投影方向。